

# Entrepôt de Données de Santé du CHU

Dossier d'architecture et de traitements — pipeline ELT médaillon sur ClickHouse, restitution Metabase, automatisation tracée.

|                                |                                               |                                 |                                     |                                   |
|--------------------------------|-----------------------------------------------|---------------------------------|-------------------------------------|-----------------------------------|
| <b>6 (+3 évol.)</b><br>SOURCES | <b>28 (+<br/>2026-08-29)</b><br>JOURS INGÉRÉS | <b>6 729</b><br>SÉJOURS FIABLES | <b>8 112</b><br>ACTES (FAIT AJOUTÉ) | <b>12/12</b><br>CONTRÔLES VÉRIFIÉ |
|--------------------------------|-----------------------------------------------|---------------------------------|-------------------------------------|-----------------------------------|

**Partie I** (§ 1-11) : socle finalisé. **Partie II** (§ 12-17) : évolution du sujet (actes médicaux, description des services) — additive. Voir aussi docs/context/07 à 09 (contexte, conception KPI-first, comparatif du corrigé niveau 1).

## 1. Le besoin

Le CHU souhaite se doter d'un **Entrepôt de Données de Santé (EDS)**. Ses données sont aujourd'hui éparpillées dans plusieurs systèmes (dossier patient, urgences, laboratoire, monitoring des chambres) et exportées **chaque jour** sous forme de fichiers, dans des formats hétérogènes. La direction veut en tirer **deux usages** :

| Public                      | Ce qu'il attend                                                                                                                                 |
|-----------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Pilotage hospitalier</b> | Durée Moyenne de Séjour par service, activité des urgences, taux de réadmission à 30 jours, relevés de constantes en alerte, charge par service |
| <b>Recherche clinique</b>   | prévalence par pathologie (taille des cohortes), description de cohorte par âge et sexe                                                         |

Les données de santé relèvent d'une **catégorie particulière** (RGPD, art. 9) : la conformité n'est pas une option mais une **contrainte de conception** présente à chaque étape. Les indicateurs doivent être **fiables, cohérents avec les sources et justifiables**.

## 2. Les sources

Le CHU dépose chaque jour ses fichiers dans source-filestorage/<source>/<AAAA-MM-JJ>/, en **lecture seule**.

Volumétries constatées sur le jeu fourni : **28 jours** d'activité (2026-08-01 à 28) pour les séjours, diagnostics et monitoring ; les patients sont livrés en **3 instantanés complets** (2026-08-26 à 28).


| Fichier                   | Format        | Volumétrie                                  | Particularité                                                   |
|---------------------------|---------------|---------------------------------------------|-----------------------------------------------------------------|
| patients.csv              | CSV           | 6 000 lignes × 3 instantanés                | contient l'identité réelle (NIR, nom, prénom) — à pseudonymiser |
| sejours.csv               | CSV           | 6 797 séjours (≈ 40 à 310 / jour)           | discharge_ts parfois vide = séjour en cours                     |
| diagnostics.json          | JSON imbriqué | ~40 Ko / jour                               | un ou plusieurs codes CIM-10 par séjour (principal / associé)   |
| monitoring.parquet        | Parquet       | 41 778 relevés (flux volumineux par nature) | constantes au chevet (FC, SpO2, température)                    |
| referentiels/services.csv | CSV           | 8 services                                  | déposé <b>le premier jour uniquement</b> (2026-08-01)           |

| Fichier                | Format | Volumétrie | Particularité |
|------------------------|--------|------------|---------------|
| referentiels/cim10.csv | CSV    | 13 codes   | idem          |

Les patients sont livrés en instantané complet : 18 000 lignes brutes (3 × 6 000) correspondent à **6 000 patients distincts**, déduplicués en silver.

L'évolution du sujet ajoute une **6e source** (actes/, Parquet) et deux référentiels (description\_service.csv, ccam.csv) dans le dépôt du **2026-08-29** — détail § 12.

### 3. Architecture cible — schéma justifié



Architecture médaille de l'EDS

Chaîne : filestorage → lake → bronze → silver → gold → dashboards, plus une étape clean (quarantaine). Python pilote, ClickHouse transforme.

#### Patron « médaille » et ELT

On charge d'abord le **brut** (lake + bronze), puis on enchaîne les transformations dans l'entrepôt (silver, gold). Ce choix **ELT** (et non ETL) se justifie ici :

- le stockage ne coûte presque rien → on garde la source brute et on peut **rejouer** une transformation ou répondre à un nouveau besoin sans ré-extraire ;
- la **traçabilité** est native (on sait toujours d'où vient la donnée — utile RGPD / audit) ;
- l'entrepôt calcule à l'échelle, là où est la donnée.

#### Pourquoi ClickHouse

| Critère                                                             | Apport pour ce projet                                                                 |
|---------------------------------------------------------------------|---------------------------------------------------------------------------------------|
| Stockage <b>colonne</b>                                             | l'analytique agrège quelques colonnes sur des millions de lignes → ne lit que l'utile |
| <b>Partitionnement</b> (PARTITION BY toYYYYMMDD(ts) sur monitoring) | <i>partition pruning</i> : une requête par jour ne lit qu'une partition               |
| Compression forte                                                   | le flux monitoring, le plus gros, tient sans difficulté                               |
| UI SQL intégrée (:8123/play)                                        | exploration et vérification immédiates                                                |
| 1 conteneur Docker                                                  | tourne sur un laptop, sans cluster                                                    |

#### Principe : transformation *dans* le moteur

La transformation bronze → silver → gold s'exécute **en SQL, dans ClickHouse**. Python se contente de recopier les fichiers puis d'envoyer les requêtes. On ne sort jamais les données du moteur pour les traiter en mémoire (pandas) : c'est l'anti-pattern classique du Big Data — ça ne passe pas à l'échelle.

## Rôle de chaque couche

| Couche | Rôle unique                                                                                                                         | Support             |
|--------|-------------------------------------------------------------------------------------------------------------------------------------|---------------------|
| Lake   | copie brute, telle quelle (patients / séjours pseudonymisés)                                                                        | fichiers data/lake/ |
| Bronze | tables typées, peu transformées, 1 table par source                                                                                 | bronze.*            |
| Clean  | journal de quarantaine des lignes écartées — artefact <b>opérationnel</b> d'audit, non analytique (alimenté pendant l'étape silver) | clean.rejects       |
| Silver | nettoyé, déduplicué, cohérent, <b>relié</b> :<br>patients → séjours → diagnostics<br>→ pathologies ; monitoring = flux autonome     | silver.*            |
| Gold   | indicateurs agrégés <b>par usage</b> (dms + fait = tables, KPI = vues)                                                              | gold.*              |

## Flux

- **Entrant** : pipeline (Python) lit le filestorage en lecture seule et recopie vers le lake.
- **Interne** : Python envoie les fichiers sql/ à ClickHouse, couche par couche (bronze, clean, silver, gold).
- **Sortant** : Metabase lit gold.\* via deux utilisateurs ClickHouse distincts (RBAC).
- **Transverse** : meta.runs (chaque exécution) et meta.ingested\_files (idempotence).

## Choix d'orchestration

Le dépôt est **quotidien** → traitement **batch**, simple et robuste. cron + Makefile suffisent : aucune infrastructure supplémentaire, rejouable, et une table de runs assure la traçabilité. Un orchestrateur (Airflow / Dagster) apporterait UI et *backfill* natifs mais serait disproportionné à cette échelle (cf. § 11).

## 4. Traitements & qualité

### Pseudonymisation à l'entrée du lake (★ bonus)

Avant toute écriture dans le lake, pipeline/steps/1\_lake.py applique :

| Champ            | Transformation                                                                                                                      |
|------------------|-------------------------------------------------------------------------------------------------------------------------------------|
| patient_id       | patient_hash = sha256(PSEUDO_SALT + ":" + patient_id) tronqué — <b>déterministe</b> (jointures préservées) et <b>non réversible</b> |
| birth_date       | → birth_year (généralisation)                                                                                                       |
| nir, nom, prenom | <b>supprimés</b> du fichier écrit                                                                                                   |
| region_code      | conservé (utile aux cohortes, non directement identifiant)                                                                          |

Le même hachage est appliqué à patient\_id dans sejours.csv → le lien patient ↔ séjour est conservé. **Aucune donnée identifiante n'atteint le lake ni l'entrepôt.** Le sel vit dans .env, hors dépôt.

### Contrôles qualité (silver) & journal de quarantaine (clean)

Principe imposé par le sujet : le traitement attendu est **simple** — on **écarte** les lignes fautives (et on déduplique les patients), **on trace** ce qu'on écarte dans clean.rejects (source, natural\_key, rule, detail). Ce journal constitue une **étape clean distincte** de la base analytique silver : c'est un artefact opérationnel d'audit, pas une table d'analyse.

Résultats sur le jeu fourni :

| Source             | Règle                                                                                        | Lignes écartées          |
|--------------------|----------------------------------------------------------------------------------------------|--------------------------|
| monitoring         | valeur hors plage physiologique (FC 20-250, SpO2 50-100, temp 30-45)                         | 858                      |
| sejours            | discharge_ts < admission_ts<br>(incohérence temporelle)                                      | 68                       |
| diagnostics        | stay_id totalement inconnu du bronze ·<br>code_cim10 hors référentiel                        | 0 (aucun cas sur ce jeu) |
| sejours / patients | birth_year aberrant · durée > 180 j ·<br>service hors référentiel · sexe non<br>normalisable | 0 (aucun cas sur ce jeu) |

Les **127 diagnostics** portés par les 68 séjours écartés pour incohérence de dates ne sont **plus rejetés** : l'erreur est sur les *dates* du séjour, pas sur le codage — la pathologie du patient reste vraie. Ils sont **conservés** dans `silver.diagnostics` (et alimentent prévalence / cohortes) tout en restant **hors** `gold.fact_sejour` (durées). Cf. § 5 et le comparatif § 16.

Bilan : **6 797** séjours bruts → **6 729** séjours fiables (99,0 %). **18 000** lignes patients (3 instantanés) → **6 000** patients (déduplication). Le fait `gold.fact_sejour` compte exactement 6 729 lignes (cf. contrôle de réconciliation, § 7).

## 5. Couche silver — modèle propre & décisions de nettoyage

Cette section explicite **pourquoi** chaque règle, et pourquoi « écarter » plutôt que « corriger ».




Schéma de la base silver

Base silver : une chaîne reliée patients → sejours → diagnostics → pathologies, plus le flux monitoring **autonome** (5 tables). Le journal des lignes écartées est **sorti de silver** — étape clean (§ 4). Les notes indiquent les bornes et l'intégrité référentielle appliquées.

## Un rôle unique par couche

Silver **ne fait que** nettoyer / dédupliquer / relier : pas de typage (rôle du bronze), pas d'agrégation (rôle du gold). La traçabilité des lignes écartées est déportée dans l'étape *clean* (`clean.rejects`) — un journal opérationnel qui n'a pas sa place dans le modèle analytique. Cette séparation stricte rend le pipeline lisible et maintenable — on sait exactement où intervenir pour chaque type de problème.

## Pourquoi cette chaîne — le grain suit la source

Le besoin métier est **centré patient** (prévalence par pathologie, cohortes), mais la donnée, elle, est produite au **grain du séjour** : `diagnostics.json` code chaque diagnostic sous un `stay_id`, jamais sous un `patient_id` (conforme au codage PMSI — le diagnostic appartient au résumé de séjour). On relie donc `diagnostics` à `sejours`, et non à `patients`, pour trois raisons :

- **Fidélité au grain** : un patient a plusieurs séjours, chacun avec son propre diagnostic principal (infarctus lors d'un séjour, BPCO six mois plus tard). Rattacher au patient obligerait à choisir arbitrairement « quel principal gagne » — on inventerait un grain absent de la source. Le type = 'principal' n'a de sens qu'**au séjour**.
- **Le besoin patient est déjà servi par jointure** : le `patient_hash` s'obtient via `diagnostics.stay_id → sejours.stay_id → sejours.patient_hash`. C'est ce chemin que matérialise `gold.fact_sejour` (qui porte à la fois `patient_hash` et `diag_principal`) et qu'exploite `kpi_recherche_prevalence` (`uniqExact(patient_hash)` par code). Une clé étrangère directe `diagnostics → patients` serait **redondante**.
- **Bénéfices de bord** : rattaché au séjour, un diagnostic hérite du filtre qualité (`INNER JOIN silver.sejours → un diagnostic sur un séjour écarté est exclu`) et de l'**ancrage temporel** (cohortes par période, lien avec la réadmission) — le patient n'a pas de date, le séjour a `admission_ts`.

Même logique pour `monitoring` : son grain est le relevé horodaté, indépendant du séjour → flux autonome (voir plus bas). Une vue « patient × pathologies » reste possible : c'est un *rollup* gold (`diagnostics → sejours → patient`), pas une relation de base.

## Déduplication des patients — garder la version la plus récente

Le sujet l'impose. Implémentation : `argMax(colonne, business_date) GROUP BY patient_hash`.

- **Pourquoi `business_date`** (date du dépôt) et non l'horodatage technique d'ingestion : la date métier est la vérité ; l'horodatage technique peut varier selon l'ordre de traitement.
- **Pourquoi fusionner et non empiler les versions** : un patient est une **entité unique** dans l'entrepôt ; la jointure séjour → patient doit être 1-1, sinon les comptages de cohortes seraient faux.

## Séjours — écarter `discharge_ts < admission_ts` (68 lignes)

On ne peut pas savoir **laquelle** des deux dates est fautive. Corriger serait arbitraire (et introduirait une donnée inventée, contraire à l'esprit RGPD). **Écarter + tracer** est auditable : 68 lignes, soit 1,0 % — impact quantifié et acceptable.

## Séjours — conserver `discharge_ts NULL`

Explicitement « pas une anomalie » (patient encore hospitalisé). **Conséquence assumée** : la DMS et `los_hours` ne sont calculés que sur les **séjours clos** (`is_closed = 1`) ; les inclure biaiserait la durée à la baisse.

## Monitoring — bornes physiologiques : écarter la ligne entière

Décision : dès qu'**une** constante renseignée est hors borne, on écarte **toute la ligne** (et non la seule valeur). Une valeur physiologiquement impossible signale une ligne corrompue (capteur, parsing) — on ne fait plus confiance aux autres colonnes de cette ligne. Un `NULL` est toléré (constante non mesurée à cet instant ≠ erreur).

## Monitoring — flux autonome (pas de contrainte de séjour)

Le monitoring est un **flux de faits volumineux** (constantes au chevet) traité **indépendamment** de `silver.sejours` : la table n'est reliée à rien. Sur ce jeu, tous les `stay_id` du monitoring existent bien dans les séjours bruts, mais **520 relevés (1,3 %)** portent sur un séjour **écarté par un contrôle qualité silver** : ils sont **conservés** — c'est de la télémétrie réelle, et aucun KPI ne joint monitoring aux séjours (`kpi_pilotage_alertes constantes` agrège par jour). Le refuser reviendrait à jeter des mesures physiologiques valides. Ce taux de rattachement partiel reste un **signal de qualité à remonter au CHU** (§ 11). Seules les bornes physiologiques restent appliquées.

## Diagnostics — séjour réel + code au référentiel (0 rejet sur ce jeu)

On garde tout diagnostic dont le `stay_id` existe **dans** `bronze.sejours` (séjour réel) et dont le `code_cim10` est **présent au référentiel** ; `patient_hash` est récupéré depuis `bronze.sejours`. On **ne rejette que** le diagnostic dont le `stay_id` est totalement inconnu (aucun cas ici) ou dont le code est hors nomenclature (aucun cas ici).

**Choix clé (aligné sur la feuille de réponses officielle)** : un séjour écarté de `silver.sejours` pour `discharge_ts < admission_ts` a une erreur sur ses **dates**, pas sur son **codage** — le patient est réellement porteur de la pathologie. Les **127 diagnostics** de ces 68 séjours sont donc **conservés** dans `silver.diagnostics` : ils comptent pour la prévalence et les cohortes de recherche (une prévalence épidémiologique ne doit pas perdre un patient à cause d'une coquille de saisie), mais restent **exclus de** `gold.fact_sejour` (durées, DMS) via l'`INNER JOIN silver.sejours`. Les codes observés alimentent `silver.pathologies`.

## Diagnostics → pathologies — le référentiel matérialisé dans le silver

`silver.pathologies` **découle des diagnostics** : ce sont les codes CIM-10 **réellement observés** dans `silver.diagnostics`, avec leur libellé canonique repris du référentiel bronze (source de vérité pour la *validation* des codes). La chaîne `diagnostics → pathologies` devient une vraie relation dans le modèle, `gold.dim_cim10` en découle, et un contrôle `verify (08)` garantit que tout code de `silver.diagnostics` est présent dans `silver.pathologies`, elle-même incluse dans le référentiel.

## Normalisation du sexe — sans perdre le patient

`multiIf` sur les variantes (H, HOMME, MALE, FEMME...). Si la valeur reste irréductible → champ vide **tracé**, mais **le patient est conservé** : un sexe manquant n'invalide pas les autres analyses (minimisation de la perte d'information).

## Contrôles ajoutés (exploration au-delà du sujet)

`birth_year` dans le futur ou `< 1900` → année ramenée à NULL (cohorte « âge inconnu »), tracé ; `service_code` de séjour absent du référentiel → écarté ; durée de séjour `> 180 j` (sans être négative) → écartée, probable erreur de saisie. Aucun cas sur le jeu fourni, mais les contrôles sont en place et se déclencheront sur des dépôts réels.

## Rebuild complet à chaque transform

Chaque couche fait `TRUNCATE + INSERT` depuis la couche amont — y compris `clean.rejects`, reconstruit à chaque run.

**Choix idempotence > performance**, assumé à l'échelle laptop : `make transform` est rejouable sans doublon. En production sur un vrai volume, on passerait à un traitement **incrémental par partition de date** et à un journal `clean.rejects` **historisé** (avec `run_id`).

## 6. Modélisation — schéma en étoile




Schéma en étoile de la couche gold

- **Fait** : fact\_sejour — 1 ligne = 1 séjour valide. Mesures : los\_days, is\_closed, is\_urgence, comptages.
- **Dimensions** : dim\_patient (sexe, région, tranche d'âge), dim\_service (code → libellé), dim\_cim10 (code → libellé, **alimentée par** silver.pathologies). La date d'admission est une **dimension dégénérée** portée par le fait.
- **Règle appliquée** : dans « KPI par X », X est une dimension et le KPI (compte / somme) sort du fait. On ne crée jamais de « fact\_patient » — le patient n'est pas un événement.

## 7. Indicateurs — définitions et chiffres justifiés

Table de fait : gold.fact\_sejour. Chaque chiffre est **reproductible** (make verify, § 10). Les définitions ci-dessous sont **alignées sur la feuille de réponses officielle des KPI**(« corrigé niveau 1 », jeu figé seed 42) — cf.

docs/context/09-corrige-niveau1-comparatif.mdpour le détail avant/après.

### Pilotage

| KPI                      | Définition                                                                                                                                                        | Valeur (jeu fourni)                                                                                                                                                  |
|--------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| DMS par service          | avg( los_hours ) / 24 sur séjours <b>clos</b> ,<br>GROUP BY service_code (+<br>dms_heures)                                                                        | de <b>2,15 j</b> (Urgences, 1 277 séjours) à <b>9,05 j</b><br>(Réanimation, 423) ; NEURO 7,06 · ONCO<br>6,87 · PNEUMO 6,20 · CARDIO 5,31 · CHIR<br>4,39 · PEDIA 3,19 |
| Activité urgences / jour | séjours du <b>service</b> URGENCES par date<br>d'admission : nb_passages,<br>nb_encore_presents,<br>duree_moy_heures (clos)                                       | <b>1 423</b> passages sur 28 j (≈ 51 / jour, 9 à 82) ;<br>durée moyenne ≈ <b>51,8 h</b> ; les 3 derniers<br>jours sont partiels                                      |
| Réadmission à 30 jours   | séjours clos suivis d'une <b>nouvelle</b><br><b>admission du même</b> patient_hash ≤ <b>30 j</b><br>; dénominateur = <b>tous</b> les séjours valides              | <b>11,59 %</b> (780 / 6 729)                                                                                                                                         |
| Relevés en alerte / jour | relevés silver.monitoring franchissant<br>une borne d'alerte clinique : <b>SpO2 &lt; 92 · FC</b><br><b>&lt; 50 ou &gt; 100 · T° &gt; 38,5</b> (au moins un seuil) | <b>3 314</b> alertes / <b>40 920</b> relevés = <b>8,1 %</b> (≈ 118<br>alertes / jour)                                                                                |
| Charge par service       | admissions, séjours en cours, patients-jours<br>cumulés                                                                                                           | Cardiologie en tête (1 601 admissions, 7 749<br>patients-jours)                                                                                                      |

| KPI             | Définition                                    | Valeur (jeu fourni)                                                 |
|-----------------|-----------------------------------------------|---------------------------------------------------------------------|
| Modes de sortie | répartition des discharge_mode (séjours clos) | domicile 50,3 % · transfert 16,7 % · mutation 16,5 % · décès 16,5 % |

### Recherche (k-anonymat : cohortes < 5 non diffusées)

| KPI                             | Définition                                                                                                  | Valeur                                                                                                                                                          |
|---------------------------------|-------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Prévalence par pathologie       | uniqExact(patient_hash) par code_cim10, <b>tous diagnostics</b> (principal + associé), HAVING ≥ 5           | N39 (infection urinaire) <b>2 234</b> · E11 (diabète) 2 177 · I50 (insuffisance cardiaque) 2 156 · J44 (BPCO) 1 775 · J18 850 — <b>11 pathologies</b> diffusées |
| Cohorte pathologie × âge × sexe | uniqExact(patient_hash) par diagnostic <b>principal</b> × tranche d'âge <b>décennale</b> × sexe, HAVING ≥ 5 | <b>89 cellules</b> diffusées (13 pathologies × tranches × M/F)                                                                                                  |

**k-anonymat en action** : cim10.csv inclut trois pathologies pédiatriques rares. E84 (Mucoviscidose, 4 patients) et Q90 (Trisomie 21, 3) ont une cohorte < 5 → leurs lignes **n'apparaissent pas** dans les vues gold.kpi\_recherche\_\* (HAVING nb\_patients >= 5) ; G12 (Amyotrophie spinale, 8) apparaît. Le seuil s'applique dans la vue, pas dans le code appelant. La feuille de réponses (usage intervenant) montre ces effectifs masqués — ils sont reproduits, hors périmètre ro\_recherche, dans le comparatif § 16.

### Justification des chiffres


make verify exécute **9 contrôles** de réconciliation qui **garantissent** ces valeurs :

- count(gold.fact\_sejour) = count(silver.sejours) = 6 729 ;
- tout stay\_id de silver provient du bronze et n'a pas été écarté par ailleurs ;
- count(patients distincts bronze) = count(silver.patients) = 6 000 ;
- aucune cohorte recherche < 5 ;
- aucun los\_hours négatif, aucune incohérence temporelle résiduelle ;
- $\Sigma$  nb\_passages (KPI urgences) = countIf(service\_code = 'URGENCES') sur le fait ;
- aucune constante hors plage résiduelle en silver ;
- tout code\_cim10 de silver.diagnostics est présent dans silver.pathologies, elle-même incluse dans le référentiel CIM-10 ;
- 09\_corrige\_niveau1 : les repères de la feuille de réponses sont atteints (réadmission 780 / 6 729 ; prévalence N39 = 2 234, E11 = 2 177, I50 = 2 156 ; DMS REA 9,05 · NEURO 7,06 ; alertes 2026-08-01 = 25 / 351 ; urgences 2026-08-01 = 46).

## 8. Visualisations


Deux dashboards Metabase provisionnés **automatiquement** et de façon idempotente par make dashboards (API REST, pipeline/steps/4\_dashboards.py).

## Dashboard « Pilotage hospitalier »



Dashboard Pilotage

## Dashboard « Recherche clinique »




Dashboard Recherche

## Démonstration du cloisonnement des droits


Le cloisonnement est porté à **deux niveaux**, le second étant la vraie garantie :

**Niveau 1 — Metabase.** Permissions de données et de collections par groupe. Un membre du groupe *Recherche* ne voit ni la base *EDS — Pilotage*, ni la collection / le dashboard *Pilotage*.



Vue d'un utilisateur Recherche

**Niveau 2 — ClickHouse RBAC** (la vraie garantie). `ro_recherche` n'a de `GRANT SELECT` que sur `gold.kpi_recherche_*`. Même en SQL libre via Metabase, une requête sur une vue de pilotage échoue.



Requête pilotage refusée pour `ro_recherche`

## 9. Gouvernance & RGPD

| Contrainte       | Mise en œuvre                                                                                                                                                                                                   |
|------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Pseudonymisation | hachage salé déterministe <b>à l'entrée du lake</b> (§ 4) ; le <i>pipeline</i> n'écrit jamais d'identité réelle dans le lake ni l'entrepôt                                                                      |
| Minimisation     | nir/nom/prenom supprimés ; birth_date → année ; âge en tranches                                                                                                                                                 |
| Cloisonnement    | 2 utilisateurs ClickHouse ( <code>ro_pilotage</code> , <code>ro_recherche</code> ) + rôles ; 2 connexions et 2 groupes Metabase (§ 8)                                                                           |
| Petits effectifs | <code>HAVING ... ≥ 5</code> <b>dans les vues</b> <code>gold.kpi_recherche_*</code> ; contrôle <code>verify</code> associé                                                                                       |
| Traçabilité      | <code>meta.runs</code> (qui, quand, quel statut) + <code>meta.ingested_files</code> (hash de chaque fichier) + logs horodatés ; <code>clean.rejects</code> journalise chaque ligne écartée (source, règle, clé) |
| Sécurité du sel  | <code>PSEUDO_SALT</code> dans <code>.env</code> (jamais committé) ; sa perte casse les jointures historiques → sauvegarde hors dépôt                                                                            |

Le jeu de données utilisé ici est **100 % synthétique** (fourni avec le sujet : noms et NIR fabriqués). Il est **versionné dans le dépôt** (`data/source-filestorage/`) pour que le pipeline s'exécute tel quel, sans import. En conditions réelles, ce dépôt — qui contient l'identité en clair le temps du hachage — resterait **hors du dépôt Git** et hors périmètre de l'entrepôt ; seul `data/lake/` (pseudonymisé) et l'entrepôt subsisteraient.

## 10. Automatisation (Partie 2)

- **Incrémental & idempotent** : `meta.ingested_files` mémorise le hash de chaque fichier écrit → ré-exécuter `ingest` ne recopie rien de connu ; les transformations font un rebuild complet → `transform` rejouable sans doublon.
- **Commande quotidienne** : `eds run-daily` enchaîne `ingest(jour)` + `transform` + `verify` dans **un seul** `meta.runs`, avec code retour propre.
- **Planification** : `crontab scripts/crontab.example` — tous les jours à 02h15 ; sur échec, une ligne [ALERTE] est écrite dans `logs/cron.log` et le run est marqué `error`.
- **Journalisation** : `logs/pipeline-AAAAMMJJ.log` (console + fichier).
- **Reprise sur incident** : `make status` pour identifier le run en échec, corriger la cause, puis `make replay DATE=<jour>` (ré-ingère + rejoue les transformations).
- **Contrôle de fiabilité** : `make verify` — 12 contrôles, `exit` ≠ 0 si l'un casse ; branché sur `run-daily` et documenté dans `.claude/skills/eds-run/SKILL.md`.

## 11. Limites & recommandations

### Alternatives écartées (et quand elles deviendraient pertinentes)

| Piste                                   | Écartée parce que                                                                           | Basculer si...                                                                    |
|-----------------------------------------|---------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------|
| <b>dbt-clickhouse</b> pour les transfos | on reste au plus près de la fiche-sujet (SQL + Python) et on limite les dépendances         | le nombre de modèles SQL explose, besoin de tests et doc auto                     |
| <b>Dagster / Airflow</b>                | lourd pour un laptop ; <code>cron</code> + <code>meta.runs</code> suffit à la démonstration | multiplication des sources, besoin de <i>backfill</i> et de dépendances complexes |
| <b>Superset</b> au lieu de Metabase     | mise en place plus lourde ; le <i>row-level security</i> n'est pas nécessaire ici           | besoin de filtrage fin par utilisateur au sein d'une même table                   |

### Passage à l'échelle du monitoring

Le flux monitoring est le plus volumineux et grossira. Le traiter comme un **flux autonome** (aucune jointure inter-tables à honorer au nettoyage) facilite ce passage à l'échelle. Recommandations : cluster ClickHouse (sharding par `stay_id`), politique de **rétenion** (TTL sur les partitions anciennes), **agrégats pré-calculés** (Materialized Views pour les alertes par jour) plutôt qu'un scan complet à chaque lecture.

### Qualité & sécurité

- Étendre les contrôles silver (doublons de `stay_id` divergents entre dépôts, valeurs de `admission_mode` / `discharge_mode` hors nomenclature).
- `silver.monitoring` (flux autonome) conserve **520 relevés (1,3 %)** portant sur un séjour écarté par un contrôle qualité silver : **conservés** (télémetrie réelle), mais ce taux de rattachement partiel est à **remonter au CHU** comme signal de qualité à la source.
- Le référentiel `services` n'est pas encore matérialisé en silver comme pathologies. **Fait dans la Partie II** : `silver.services` (promu + enrichi) rend la chaîne symétrique.
- Chiffrement au repos des volumes, journalisation des accès Metabase, rotation du sel de pseudonymisation avec table de correspondance sécurisée.
- Sur ce jeu, `discharge_mode` est renseigné sur tous les séjours clos ; sur un dépôt réel, un taux de non-renseignement serait à suivre comme problème **à la source**.

## Partie II — Évolution du sujet : actes médicaux & description des services

Reçue après la finalisation de la Partie I. Consigne : « faites évoluer votre entrepôt — sans tout refaire, sans rien casser ». La Partie I (§ 1-11) reste le socle ; cette partie est **additive**. Sources : docs/SUJET-EVOLUTION-nouvelles-kpi.pdf, docs/context/07-evolution-contexte.md à 09-corrige-niveau1-comparatif.md.

### 12. Contexte de l'évolution

Le CHU **ajoute** des données (il n'en modifie aucune), dans un dépôt daté **2026-08-29** :

| Fichier                                         | Format  | Contenu                                                              | Volume                           |
|-------------------------------------------------|---------|----------------------------------------------------------------------|----------------------------------|
| referentiels/2026-08-29/description_service.csv | CSV     | enrichit les services :<br>categorie, capacite_lits,<br>pole         | 7 lignes ( <b>NEURO absent</b> ) |
| referentiels/2026-08-29/ccam.csv                | CSV     | nomenclature des actes :<br>code_ccam, libelle,<br>tarif_euros (T2A) | 8 codes                          |
| actes/2026-08-29/actes.parquet                  | Parquet | nouveau <b>flux de faits</b> :<br>stay_id, code_ccam,<br>acte_ts     | 8 112 actes                      |

service\_label → categorie → pole sont **trois niveaux d'agrégation croissants** du mêmeaxe « service » (analyser par service, par catégorie, par pôle) — une hiérarchie, pas uneredondance.

**Cinq KPI** sont demandés (E1 activité/DMS par catégorie · E2 actes par service · E3 actespar type · E4 densité d'actes par lit · E5 montant T2A par service) avec **deux piègesexplicités** : (1) le référentiel de description est **incomplet** (NEURO non décrit) ;(2) « actes par service » — le service est porté par le **séjour**, pas par l'acte.

### 13. Analyse — concevoir le silver à partir des KPI

Démarche : **partir des KPI**, en déduire les tables strictement nécessaires (détail :docs/context/08-evolution-silver-kpi.md).

| KPI    | Table créée / étendue                                                 | Justification                                                                                                          |
|--------|-----------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------|
| E1     | silver.services → gold.dim_service (+ categorie, capacite_lits, pole) | référentiel <b>promu en silver</b> (comme pathologies) car la description doit être nettoyée / complétée avant le gold |
| E2, E5 | silver.actes → gold.fact_acte                                         | fait « acte » (grain = 1 acte) ; service_code <b>résolu dans le silver</b>                                             |
| E3     | silver.ccam → gold.dim_ccam                                           | référentiel matérialisé (codes CCAM observés), miroir de pathologies                                                   |
| E4     | capacite_lits de gold.dim_service                                     | dénominateur de densité                                                                                                |

#### Piège 1 — service non décrit (NEURO)

silver.services part de la **liste autoritaire** bronze.ref\_services (**8 services**) etLEFT JOIN la description. NEURO, absent de description\_service.csv, est **conservé** :categorie / pole = '(non décrit)', capacite\_lits = NULL, is\_described = 0, tracé clean.rejects (service\_sans\_description — **audit, pas exclusion**).

- L'exclure ferait perdre 1 208 séjours / 1 471 actes aux analyses « par catégorie » etcasserait la réconciliation avec fact\_sejour.
- Deviner sa catégorie reviendrait à **inventer** une donnée absente de la source.
- Résultat : KPI E1 montre un groupe (non décrit) explicite ; KPI E4 densité = NULLpour NEURO. Le trou est **visible et remontable au CHU**.

## Piège 2 — le service vient du séjour


Le `service_code` (et le `patient_hash`) sont résolus **une seule fois**, dans `silver.actes`, par `bronze.actes` → `bronze.sejours`. `gold.fact_acte` porte ces `service_code` **dénormalisé** → **aucune vue gold ne joint `fact_acte` à `fact_sejour`**. Joindre deux tables de faits de grains différents (acte / séjour) ferait exploser les lignes (produit acte × séjour du même patient) et fausserait tous les comptages : un fait ne se joint qu'à des **dimensions**. Contrôle `11_actes_service_provenance` : 0 écart entre le service de l'acte et celui de son séjour.

## Décisions de nettoyage des actes (miroir des diagnostics)

Un acte porté par un séjour écarté pour **dates incohérentes** reste **réel et facturable** : on le **conserve** (82 actes), service et patient pris dans `bronze.sejours`. On n'écarte (et trace) que l'acte au `stay_id` totalement inconnu ou au `code_ccam` hors nomenclature — **0 cas** sur ce dépôt.

## 14. Modèle après évolution — comparatif

### Couche silver — 5 tables → 8



Base silver après évolution

|               | Partie I                                                             | Partie II                                                        |
|---------------|----------------------------------------------------------------------|------------------------------------------------------------------|
| Tables silver | patients, sejours, diagnostics, pathologies, monitoring              | + services, actes, ccam                                          |
| Chaîne        | patients → sejours → diagnostics → pathologies ; monitoring autonome | idem + services → sejours et sejours → actes ← ccam              |
| diagnostics   | rattaché à un séjour <i>valide</i>                                   | rattaché à un séjour <i>réel</i> (porte patient_hash) — cf. § 16 |

## Couche gold — schéma en étoile étendu




Schéma en étoile après évolution

|                 | Partie I                                              | Partie II                                                               |
|-----------------|-------------------------------------------------------|-------------------------------------------------------------------------|
| Faits           | fact_sejour                                           | + fact_acte (grain = 1 acte ; mesure = tarif_euros)                     |
| Dimensions      | dim_patient, dim_service, dim_cim10                   | dim_service <b>enrichie</b> (categorie, capacite_lits, pole) + dim_ccam |
| Règle respectée | KPI par X $\Rightarrow$ X dimension, KPI issu du fait | idem — fact_acte ne se joint qu'à des dimensions, jamais à fact_sejour  |

## Non-régression

gold.fact\_sejour = **6 729** (inchangé). Les 6 KPI de la Partie I sont inchangés dans leur résultat (test test\_non\_regression\_fact\_sejour, contrôle 01). dim\_service gagne des colonnes sans en retirer  $\rightarrow$  les vues existantes (qui ne lisent que service\_label) ne bougent pas.


## 15. Les 5 nouveaux indicateurs — définitions & valeurs

Vues gold.kpi\_pilotage\_\*, SQL SECURITY DEFINER, GRANT SELECT ... TO role\_pilotage(même public que le pilotage). Valeurs sur le jeu fourni (8 112 actes) :

| KPI                                      | Définition                                                    | Valeur (extrait)                                                                                                                         |
|------------------------------------------|---------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------|
| <b>E1 · Activité + DMS par catégorie</b> | count() séjours + avg(los_hours)/24 (clos) GROUP BY categorie | medecine 2 652 séj / 5,71 j · urgences 1 423 / 2,15 j · (non décrit) <b>1 208 / 7,06 j</b> (NEURO) · reanimation 467 / 9,05 j            |
| <b>E2 · Actes par service</b>            | count() actes par service + count() / nb_séjours_du_service   | CARDIO 1 935 actes (1,21 / séjour) · URGENCES 1 731 (1,22) · NEURO 1 471 (1,22) · ONCO 241 (1,14)                                        |
| <b>E3 · Actes par type</b>               | count() + part GROUP BY code_ccam                             | Radiographie du thorax 1 043 (12,9 %) · Consultation de suivi 1 039 · Coronarographie 1 030 — répartition $\approx$ uniforme sur 8 actes |
| <b>E4 · Densité d'actes par lit</b>      | count(actes) / capacite_lits par service                      | URGENCES <b>86,6</b> · CARDIO 64,5 · PNEUMO 36,0 · REA 35,2 · ... · <b>NEURO = NULL</b> (service non décrit)                             |
| <b>E5 · Montant T2A par service</b>      | sum(tarif_euros) par service                                  | CARDIO <b>521 655 €</b> · URGENCES 478 585 € · NEURO 393 850 € · ... · ONCO 64 265 € (total $\approx$ 2,20 M€)                           |

## Restitution — 3e dashboard Metabase

make dashboards provisionne un **3e dashboard** « *Pilotage — plateau technique & T2A* » (5 cartes, collection Pilotage), à côté des 2 dashboards de la Partie I qui restent intacts. Cloisonnement inchangé : ro\_recherche sur ces vues → ACCESS\_DENIED.



*Dashboard plateau technique & T2A*

## 16. Comparatif — alignement sur la feuille de réponses officielle (corrigé niveau 1)

Détail complet : docs/context/09-corrige-niveau1-comparatif.md. La feuille de réponses officielle (jeu figé seed 42) **confirme nos points de contrôle silver** (18 000 → 6 000 · 6 797 → 6 729 · 41 778 → 40 920) mais **révèle des définitions de KPI différentes** des choix initiaux de la Partie I. Alignement effectué :

| KPI                | Avant                                      | Après (feuille)                                                                  | Cause                                                                              |
|--------------------|--------------------------------------------|----------------------------------------------------------------------------------|------------------------------------------------------------------------------------|
| Réadmission 30 j   | 10,54 % (637 / 6 046 clos)                 | <b>11,59 % (780 / 6 729)</b>                                                     | dénominateur = tous les séjours ; réadmission vers un séjour encore ouvert comptée |
| Activité urgences  | admission_mode = 'urgence' (tous services) | <b>service URGENCES par jour</b>                                                 | « urgences » = le service, pas le mode                                             |
| Alertes constantes | FC < 40 / > 120 · T° < 35                  | <b>SpO2 &lt; 92 · FC &lt; 50 / &gt; 100 · T° &gt; 38,5</b>                       | seuils cliniques différents                                                        |
| Prévalence         | diagnostic <b>principal</b> seul           | <b>tous diagnostics</b> , y compris séjours à dates fausses → <b>N39 = 2 234</b> | prévalence épidémiologique = tout patient porteur                                  |
| Cohorte            | age_band × sex global, tranches larges     | <b>par pathologie principale × tranche décennale × sexe</b>                      | granularité et bornes                                                              |

Seul impact silver : silver.diagnostics porte désormais patient\_hash et **conserve les 127 diagnostics** des 68 séjours écartés pour dates incohérentes (le codage est valide, seules les dates sont fausses) — ces diagnostics restent **hors** fact\_sejour. Un contrôle verify dédié (09-corrige-niveau1) **verrouille** les repères chiffrés de la feuille.

## 17. Non-régression & fiabilité — 12 contrôles [verify](#)

| #     | Contrôle                                          | Portée   |
|-------|---------------------------------------------------|----------|
| 01-03 | fait ↔ silver ↔ bronze (séjours, patients)        | Partie I |
| 04    | k-anonymat : aucune cohorte recherche < 5 exposée | Partie I |
| 05    | cohérence temporelle résiduelle                   | Partie I |

| #  | Contrôle                                                       | Portée              |
|----|----------------------------------------------------------------|---------------------|
| 06 | $\Sigma$ nb_passages urgences =<br>countIf(service = URGENCES) | Partie I (réaligné) |
| 07 | bornes physiologiques monitoring                               | Partie I            |
| 08 | intégrité diagnostics → pathologies<br>→ référentiel           | Partie I            |
| 09 | <b>repères de la feuille de réponses atteints</b>              | corrigé niveau 1    |
| 10 | count(fact_acte) =<br>count(silver.actes)                      | évolution           |
| 11 | service de l'acte = service de son séjour<br>(piège 2)         | évolution           |
| 12 | intégrité actes → ccam →<br>référentiel                        | évolution           |

Reprise : make replay DATE=2026-08-29 ré-ingère le dépôt évolution et rejoue lestransformations. make all reste valable à froid (l'évolution est dans data/source-filestorage/, versionnée).