

Entrepôt de Données de Santé du CHU

Dossier d'architecture et de traitements — pipeline ELT médaillon sur ClickHouse, restitution Metabase, automatisation tracée.

6 (+3 évol.) SOURCES	28 (+ 2026-08-29) JOURS INGÉRÉS	6 729 SÉJOURS FIABLES	8 112 ACTES (FAIT AJOUTÉ)	12/12 CONTRÔLES VÉRIFIÉS
--------------------------------	---	---------------------------------	-------------------------------------	------------------------------------

Partie I (§ 1-11) : socle finalisé. **Partie II** (§ 12-17) : évolution du sujet (actes médicaux, description des services) — additive. Voir aussi docs/context/07 à 09 (contexte, conception KPI-first, comparatif du corrigé niveau 1).

1. Le besoin

Le CHU souhaite se doter d'un **Entrepôt de Données de Santé (EDS)**. Ses données sont aujourd'hui éparpillées dans plusieurs systèmes (dossier patient, urgences, laboratoire, monitoring des chambres) et exportées **chaque jour** sous forme de fichiers, dans des formats hétérogènes. La direction veut en tirer **deux usages** :

Public	Ce qu'il attend
Pilotage hospitalier	Durée Moyenne de Séjour par service, activité des urgences, taux de réadmission à 30 jours, relevés de constantes en alerte, charge par service
Recherche clinique	prévalence par pathologie (taille des cohortes), description de cohorte par âge et sexe

Les données de santé relèvent d'une **catégorie particulière** (RGPD, art. 9) : la conformité n'est pas une option mais une **contrainte de conception** présente à chaque étape. Les indicateurs doivent être **fiables, cohérents avec les sources et justifiables**.

2. Les sources

Le CHU dépose chaque jour ses fichiers dans source-filestorage/<source>/<AAAA-MM-JJ>/, en **lecture seule**.


Volumétries constatées sur le jeu fourni : **28 jours** d'activité (2026-08-01 à 28) pour les séjours, diagnostics et monitoring ; les patients sont livrés en **3 instantanés complets** (2026-08-26 à 28).

Fichier	Format	Volumétrie	Particularité
patients.csv	CSV	6 000 lignes × 3 instantanés	contient l'identité réelle (NIR, nom, prénom) — à pseudonymiser
sejours.csv	CSV	6 797 séjours (≈ 40 à 310 / jour)	discharge_ts parfois vide = séjour en cours
diagnostics.json	JSON imbriqué	~40 Ko / jour	un ou plusieurs codes CIM-10 par séjour (principal / associé)
monitoring.parquet	Parquet	41 778 relevés (flux volumineux par nature)	constantes au chevet (FC, SpO2, température)
referentiels/services.csv	CSV	8 services	déposé le premier jour uniquement (2026-08-01)
referentiels/cim10.csv	CSV	13 codes	idem

Les patients sont livrés en instantané complet : 18 000 lignes brutes (3 × 6 000) correspondent à **6 000 patients distincts**, dédupliqués en silver.

L'évolution du sujet ajoute une **6e source** (actes/, Parquet) et deux référentiels (description_service.csv, ccam.csv) dans le dépôt du **2026-08-29** — détail § 12.

3. Architecture cible — schéma justifié



Architecture médaille de l'EDS

Chaîne : filestorage → lake → bronze → silver → gold → dashboards, plus une étape clean (quarantaine). Python pilote, ClickHouse transforme.

Patron « médaille » et ELT

On charge d'abord le **brut** (lake + bronze), puis on enchaîne les transformations dans l'entrepôt (silver, gold). Ce choix **ELT** (et non ETL) se justifie ici :

- le stockage ne coûte presque rien → on garde la source brute et on peut **rejouer** une transformation ou répondre à un nouveau besoin sans ré-extraire ;
- la **traçabilité** est native (on sait toujours d'où vient la donnée — utile RGPD / audit) ;
- l'entrepôt calcule à l'échelle, là où est la donnée.

Pourquoi ClickHouse

Critère	Apport pour ce projet
Stockage colonne	l'analytique agrège quelques colonnes sur des millions de lignes → ne lit que l'utile
Partitionnement (PARTITION BY toYYYYMMDD(ts) sur monitoring)	<i>partition pruning</i> : une requête par jour ne lit qu'une partition
Compression forte	le flux monitoring, le plus gros, tient sans difficulté
UI SQL intégrée (:8123/play)	exploration et vérification immédiates
1 conteneur Docker	tourne sur un laptop, sans cluster

Principe : transformation *dans* le moteur

La transformation bronze → silver → gold s'exécute **en SQL, dans ClickHouse**. Python se contente de recopier les fichiers puis d'envoyer les requêtes. On ne sort jamais les données du moteur pour les traiter en mémoire (pandas) : c'est l'anti-pattern classique du Big Data — ça ne passe pas à l'échelle.

Rôle de chaque couche

Couche	Rôle unique	Support
Lake	copie brute, telle quelle (patients / séjours pseudonymisés)	fichiers data / lake /

Couche	Rôle unique	Support
Bronze	tables typées, peu transformées, 1 table par source	bronze.*
Clean	journal de quarantaine des lignes écartées — artefact opérationnel d'audit, non analytique (alimenté pendant l'étape silver)	clean.rejects
Silver	nettoyé, dédoublé, cohérent, relié : patients → sejours → diagnostics → pathologies ; monitoring = flux autonome	silver.*
Gold	indicateurs agrégés par usage (dms + fait = tables, KPI = vues)	gold.*

Flux

- **Entrant** : pipeline (Python) lit le filestorage en lecture seule et recopie vers le lake.
- **Interne** : Python envoie les fichiers sql/ à ClickHouse, couche par couche (bronze, clean, silver, gold).
- **Sortant** : Metabase lit gold.* via deux utilisateurs ClickHouse distincts (RBAC).
- **Transverse** : meta.runs (chaque exécution) et meta.ingested_files (idempotence).

Choix d'orchestration

Le dépôt est **quotidien** → traitement **batch**, simple et robuste. cron + Makefile suffisent : aucune infrastructure supplémentaire, rejouable, et une table de runs assure la traçabilité. Un orchestrateur (Airflow / Dagster) apporterait UI et *backfill* natifs mais serait disproportionné à cette échelle (cf. § 11).

4. Traitements & qualité

Pseudonymisation à l'entrée du lake (★ bonus)

Avant toute écriture dans le lake, pipeline/steps/1_lake.py applique :

Champ	Transformation
patient_id	patient_hash = sha256(PSEUDO_SALT + ":" + patient_id) tronqué — déterministe (jointures préservées) et non réversible
birth_date	→ birth_year (généralisation)
nir, nom, prenom	supprimés du fichier écrit
region_code	conservé (utile aux cohortes, non directement identifiant)

Le même hachage est appliqué à patient_id dans sejours.csv → le lien patient ↔ séjour est conservé. **Aucune donnée identifiante n'atteint le lake ni l'entrepôt**. Le sel vit dans .env, hors dépôt.

Contrôles qualité (silver) & journal de quarantaine (clean)

Principe imposé par le sujet : le traitement attendu est **simple** — on **écarte** les lignes fautives (et on déduplique les patients), **on trace** ce qu'on écarte dans clean.rejects (source, natural_key, rule, detail). Ce journal constitue une **étape clean distincte** de la base analytique silver : c'est un artefact opérationnel d'audit, pas une table d'analyse. Résultats sur le jeu fourni :

Source	Règle	Lignes écartées
monitoring	valeur hors plage physiologique (FC 20-250, SpO2 50-100, temp 30-45)	858
sejours	discharge_ts < admission_ts (incohérence temporelle)	68

Source	Règle	Lignes écartées
diagnostics	stay_id totalement inconnu du bronze · code_cim10 hors référentiel	0 (aucun cas sur ce jeu)
sejours / patients	birth_year aberrant · durée > 180 j · service hors référentiel · sexe non normalisable	0 (aucun cas sur ce jeu)
referentiels	service_sans_description (service absent de la description — audit, pas exclusion)	1 (NEURO) — cf. § 13

Les **127 diagnostics** portés par les 68 séjours écartés pour incohérence de dates ne sont **plus rejetés** : l'erreur est sur les *dates* du séjour, pas sur le codage — la pathologie du patient reste vraie. Ils sont **conservés** dans `silver.diagnostics` (et alimentent prévalence / cohortes) tout en restant **hors** `gold.fact_sejour` (durées). Cf. § 5 et le comparatif § 16.

Bilan : **6 797** séjours bruts → **6 729** séjours fiables (99,0 %). **18 000** lignes patients (3 instantanés) → **6 000** patients (déduplication). Le fait `gold.fact_sejour` compte exactement 6 729 lignes (cf. contrôle de réconciliation, § 7).

5. Couche silver — modèle propre & décisions de nettoyage

Cette section explicite **pourquoi** chaque règle, et pourquoi « écarté » plutôt que « corrigé ».




Schéma de la base *silver*

Base *silver* : une chaîne reliée patients → sejours → diagnostics → pathologies, plus le flux **monitoring autonome** (5 tables). Le journal des lignes écartées est **sorti de silver** — étape **clean** (§ 4). Les notes indiquent les bornes et l'intégrité référentielle appliquées.

Un rôle unique par couche

Silver **ne fait que** nettoyer / dédupliquer / relier : pas de typage (rôle du bronze), pas d'agrégation (rôle du gold). La traçabilité des lignes écartées est déportée dans l'étape *clean* (`clean.rejects`) — un journal opérationnel qui n'a pas sa place dans le modèle analytique. Cette séparation stricte rend le pipeline lisible et maintenable — on sait exactement où intervenir pour chaque type de problème.

Pourquoi cette chaîne — le grain suit la source

Le besoin métier est **centré patient** (prévalence par pathologie, cohortes), mais la donnée, elle, est produite au **grain du séjour** : `diagnostics.json` code chaque diagnostic sous un `stay_id`, jamais sous un `patient_id` (conforme au codage PMSI — le diagnostic appartient au résumé de séjour). On relie donc `diagnostics` à `sejours`, et non à `patients`, pour trois raisons :

- **Fidélité au grain** : un patient a plusieurs séjours, chacun avec son propre diagnostic principal (infarctus lors d'un séjour, BPCO six mois plus tard). Rattacher au patient obligerait à choisir arbitrairement « quel principal gagne » — on inventerait un grain absent de la source. Le type = 'principal' n'a de sens qu'**au séjour**.
- **Le besoin patient est déjà servi par jointure** : le `patient_hash` s'obtient via `diagnostics.stay_id → sejours.stay_id → sejours.patient_hash`. C'est ce chemin que matérialise `gold.fact_sejour` (qui porte à la fois `patient_hash` et `diag_principal`) et qu'exploite `kpi_recherche_prevalence` (`uniqExact(patient_hash)` par code). Une clé étrangère directe `diagnostics → patients` serait **redondante**.
- **Bénéfices de bord** : rattaché au séjour, un diagnostic hérite du filtre qualité (`INNER JOIN silver.sejours → un diagnostic sur un séjour écarté est exclu`) et de l'**ancrage temporel** (cohortes par période, lien avec la réadmission) — le patient n'a pas de date, le séjour a `admission_ts`.

Même logique pour `monitoring` : son grain est le relevé horodaté, indépendant du séjour → flux autonome (voir plus bas). Une vue « patient × pathologies » reste possible : c'est un *rollup* gold (`diagnostics → sejours → patient`), pas une relation de base.

Déduplication des patients — garder la version la plus récente

Le sujet l'impose. Implémentation : `argMax(colonne, business_date) GROUP BY patient_hash`.

- **Pourquoi `business_date`** (date du dépôt) et non l'horodatage technique d'ingestion : la date métier est la vérité ; l'horodatage technique peut varier selon l'ordre de traitement.
- **Pourquoi fusionner et non empiler les versions** : un patient est une **entité unique** dans l'entrepôt ; la jointure séjour → patient doit être 1-1, sinon les comptages de cohortes seraient faux.

Séjours — écarter `discharge_ts < admission_ts` (68 lignes)

On ne peut pas savoir **laquelle** des deux dates est fautive. Corriger serait arbitraire (et introduirait une donnée inventée, contraire à l'esprit RGPD). **Écarter + tracer** est auditable : 68 lignes, soit 1,0 % — impact quantifié et acceptable.

Séjours — conserver `discharge_ts NULL`

Explicitement « pas une anomalie » (patient encore hospitalisé). **Conséquence assumée** : la DMS et `los_hours` ne sont calculés que sur les **séjours clos** (`is_closed = 1`) ; les inclure biaiserait la durée à la baisse.

Monitoring — bornes physiologiques : écarter la ligne entière

Décision : dès qu'**une** constante renseignée est hors borne, on écarte **toute la ligne** (et non la seule valeur). Une valeur physiologiquement impossible signale une ligne corrompue (capteur, parsing) — on ne fait plus confiance aux autres colonnes de cette ligne. Un `NULL` est toléré (constante non mesurée à cet instant ≠ erreur).

Monitoring — flux autonome (pas de contrainte de séjour)

Le monitoring est un **flux de faits volumineux** (constantes au chevet) traité **indépendamment** de `silver.sejours` : la table n'est reliée à rien. Sur ce jeu, tous les `stay_id` du monitoring existent bien dans les séjours bruts, mais **520 relevés (1,3 %)** portent sur un séjour **écarté par un contrôle qualité silver** : ils sont **conservés** — c'est de la télémétrie réelle, et aucun KPI ne joint monitoring aux séjours (`kpi_pilotage_alertes constantes` agrège par jour). Le refuser reviendrait à jeter des mesures physiologiques valides. Ce taux de rattachement partiel reste un **signal de qualité à remonter au CHU** (§ 11). Seules les bornes physiologiques restent appliquées.

Diagnostics — séjour réel + code au référentiel (0 rejet sur ce jeu)

On garde tout diagnostic dont le `stay_id` existe **dans** `bronze.sejours` (séjour réel) et dont le `code_cim10` est **présent au référentiel** ; `patient_hash` est récupéré depuis `bronze.sejours`. On **ne rejette que** le diagnostic dont le `stay_id` est totalement inconnu (aucun cas ici) ou dont le code est hors nomenclature (aucun cas ici).

Choix clé (aligné sur la feuille de réponses officielle) : un séjour écarté de `silver.sejours` pour `discharge_ts < admission_ts` a une erreur sur ses **dates**, pas sur son **codage** — le patient est réellement porteur de la pathologie. Les **127** diagnostics de ces 68 séjours sont donc **conservés** dans `silver.diagnostics` : ils comptent pour la prévalence et les cohortes de recherche (une prévalence épidémiologique ne doit pas perdre un patient à cause d'une coquille de saisie), mais restent **exclus de** `gold.fact_sejour` (durées, DMS) via l'`INNER JOIN silver.sejours`. Les codes observés alimentent `silver.pathologies`.

Diagnostics → pathologies — le référentiel matérialisé dans le silver

`silver.pathologies` **découle des diagnostics** : ce sont les codes CIM-10 **réellement observés** dans `silver.diagnostics`, avec leur libellé canonique repris du référentiel bronze (source de vérité pour la *validation* des codes). La chaîne `diagnostics → pathologies` devient une vraie relation dans le modèle, `gold.dim_cim10` en découle, et un contrôle `verify (08)` garantit que tout code de `silver.diagnostics` est présent dans `silver.pathologies`, elle-même incluse dans le référentiel.

Normalisation du sexe — sans perdre le patient

`multiIf` sur les variantes (H, HOMME, MALE, FEMME...). Si la valeur reste irréductible → champ vide **tracé**, mais **le patient est conservé** : un sexe manquant n'invalide pas les autres analyses (minimisation de la perte d'information).

Contrôles ajoutés (exploration au-delà du sujet)

`birth_year` dans le futur ou `< 1900` → année ramenée à NULL (cohorte « âge inconnu »), tracé ; `service_code` de séjour absent du référentiel → écarté ; durée de séjour `> 180 j` (sans être négative) → écartée, probable erreur de saisie. Aucun cas sur le jeu fourni, mais les contrôles sont en place et se déclencheront sur des dépôts réels.

Rebuild complet à chaque transform

Chaque couche fait `TRUNCATE + INSERT` depuis la couche amont — y compris `clean.rejects`, reconstruit à chaque run.

Choix idempotence > performance, assumé à l'échelle laptop : `make transform` est rejouable sans doublon. En production sur un vrai volume, on passerait à un traitement **incrémental par partition de date** et à un journal `clean.rejects` **historisé** (avec `run_id`).

6. Modélisation — schéma en étoile




Schéma en étoile de la couche gold

- **Fait** : fact_sejour — 1 ligne = 1 séjour valide. Mesures : los_days, is_closed, is_urgence, comptages.
- **Dimensions** : dim_patient (sexe, région, tranche d'âge), dim_service (code → libellé), dim_cim10 (code → libellé, **alimentée par** silver.pathologies). La date d'admission est une **dimension dégénérée** portée par le fait.
- **Règle appliquée** : dans « KPI par X », X est une dimension et le KPI (compte / somme) sort du fait. On ne crée jamais de « fact_patient » — le patient n'est pas un événement.

7. Indicateurs — définitions et chiffres justifiés

Table de fait : gold.fact_sejour. Chaque chiffre est **reproductible** (make verify, § 10). Les définitions ci-dessous sont **alignées sur la feuille de réponses officielle des KPI** (« corrigé niveau 1 », jeu figé seed 42) — cf.

docs/context/09-corrige-niveau1-comparatif.md pour le détail avant/après.

Pilotage

KPI	Définition	Valeur (jeu fourni)
DMS par service	avg(los_hours) / 24 sur séjours clos , GROUP BY service_code (+ dms_heures)	de 2,15 j (Urgences, 1 277 séjours) à 9,05 j (Réanimation, 423) ; NEURO 7,06 · ONCO 6,87 · PNEUMO 6,20 · CARDIO 5,31 · CHIR 4,39 · PEDIA 3,19
Activité urgences / jour	séjours du service URGENCES par date d'admission : nb_passages, nb_encore_presents, duree_moy_heures (clos)	1 423 passages sur 28 j (≈ 51 / jour, 9 à 82) ; durée moyenne ≈ 51,8 h ; les 3 derniers jours sont partiels
Réadmission à 30 jours	séjours clos suivis d'une nouvelle admission du même patient_hash ≤ 30 j ; dénominateur = tous les séjours valides	11,59 % (780 / 6 729)
Relevés en alerte / jour	relevés silver.monitoring franchissant une borne d'alerte clinique : SpO2 < 92 · FC < 50 ou > 100 · T° > 38,5 (au moins un seuil)	3 314 alertes / 40 920 relevés = 8,1 % (≈ 118 alertes / jour)
Charge par service	admissions, séjours en cours, patients-jours cumulés	Cardiologie en tête (1 601 admissions, 7 749 patients-jours)

KPI	Définition	Valeur (jeu fourni)
Modes de sortie	répartition des discharge_mode (séjours clos)	domicile 50,3 % · transfert 16,7 % · mutation 16,5 % · décès 16,5 %

Recherche (k-anonymat : cohortes < 5 non diffusées)

KPI	Définition	Valeur
Prévalence par pathologie	uniqExact(patient_hash) par code_cim10, tous diagnostics (principal + associé), HAVING ≥ 5	N39 (infection urinaire) 2 234 · E11 (diabète) 2 177 · I50 (insuffisance cardiaque) 2 156 · J44 (BPCO) 1 775 · J18 850 — 11 pathologies diffusées
Cohorte pathologie × âge × sexe	uniqExact(patient_hash) par diagnostic principal × tranche d'âge décennale × sexe, HAVING ≥ 5	89 cellules diffusées (13 pathologies × tranches × M/F)

k-anonymat en action : cim10.csv inclut trois pathologies pédiatriques rares. E84 (Mucoviscidose, 4 patients) et Q90 (Trisomie 21, 3) ont une cohorte < 5 → leurs lignes **n'apparaissent pas** dans les vues gold.kpi_recherche_* (HAVING nb_patients >= 5) ; G12 (Amyotrophie spinale, 8) apparaît. Le seuil s'applique dans la vue, pas dans le code appelant. La feuille de réponses (usage intervenant) montre ces effectifs masqués — ils sont reproduits, hors périmètre ro_recherche, dans le comparatif § 16.

Justification des chiffres


make verify exécute **12 contrôles** de réconciliation (dont 9 portent sur la Partie I) qui **garantissent** ces valeurs :

- count(gold.fact_sejour) = count(silver.sejours) = 6 729 ;
- tout stay_id de silver provient du bronze et n'a pas été écarté par ailleurs ;
- count(patients distincts bronze) = count(silver.patients) = 6 000 ;
- aucune cohorte recherche < 5 ;
- aucun los_hours négatif, aucune incohérence temporelle résiduelle ;
- Σ nb_passages (KPI urgences) = countIf(service_code = 'URGENCES') sur le fait ;
- aucune constante hors plage résiduelle en silver ;
- tout code_cim10 de silver.diagnostics est présent dans silver.pathologies, elle-même incluse dans le référentiel CIM-10 ;
- 09_corrige_niveau1 : les repères de la feuille de réponses sont atteints (réadmission 780 / 6 729 ; prévalence N39 = 2 234, E11 = 2 177, I50 = 2 156 ; DMS REA 9,05 · NEURO 7,06 ; alertes 2026-08-01 = 25 / 351 ; urgences 2026-08-01 = 46).

8. Visualisations


Deux dashboards Metabase pour la Partie I, provisionnés **automatiquement** et de façon idempotente par make dashboards (API REST, pipeline/steps/4_dashboards.py). Un **3e dashboard** « *Pilotage — plateau technique & T2A* » est ajouté par l'évolution du sujet (§ 15).

Dashboard « Pilotage hospitalier »



Dashboard Pilotage

Dashboard « Recherche clinique »




Dashboard Recherche

Démonstration du cloisonnement des droits


Le cloisonnement est porté à **deux niveaux**, le second étant la vraie garantie :

Niveau 1 — Metabase. Permissions de données et de collections par groupe. Un membre du groupe *Recherche* ne voit ni la base *EDS — Pilotage*, ni la collection / le dashboard *Pilotage*.



Vue d'un utilisateur Recherche

Niveau 2 — ClickHouse RBAC (la vraie garantie). `ro_recherche` n'a de `GRANT SELECT` que sur `gold.kpi_recherche_*`. Même en SQL libre via Metabase, une requête sur une vue de pilotage échoue.



Requête pilotage refusée pour `ro_recherche`

9. Gouvernance & RGPD

Contrainte	Mise en œuvre
Pseudonymisation	hachage salé déterministe à l'entrée du lake (§ 4) ; le <i>pipeline</i> n'écrit jamais d'identité réelle dans le lake ni l'entrepôt
Minimisation	nir/nom/prenom supprimés ; birth_date → année ; âge en tranches
Cloisonnement	2 utilisateurs ClickHouse (<code>ro_pilotage</code> , <code>ro_recherche</code>) + rôles ; 2 connexions et 2 groupes Metabase (§ 8)
Petits effectifs	<code>HAVING ... ≥ 5</code> dans les vues <code>gold.kpi_recherche_*</code> ; contrôle <code>verify</code> associé
Traçabilité	<code>meta.runs</code> (qui, quand, quel statut) + <code>meta.ingested_files</code> (hash de chaque fichier) + logs horodatés ; <code>clean.rejects</code> journalise chaque ligne écartée (source, règle, clé)
Sécurité du sel	<code>PSEUDO_SALT</code> dans <code>.env</code> (jamais committé) ; sa perte casse les jointures historiques → sauvegarde hors dépôt

Le jeu de données utilisé ici est **100 % synthétique** (fourni avec le sujet : noms et NIR fabriqués). Il est **versionné dans le dépôt** (`data/source-filestorage/`) pour que le pipeline s'exécute tel quel, sans import. En conditions réelles, ce dépôt — qui contient l'identité en clair le temps du hachage — resterait **hors du dépôt Git** et hors périmètre de l'entrepôt ; seul `data/lake/` (pseudonymisé) et l'entrepôt subsisteraient.

10. Automatisation (Partie 2)

- **Incrémental & idempotent** : `meta.ingested_files` mémorise le hash de chaque fichier écrit → ré-exécuter `ingest` ne recopie rien de connu ; les transformations font un rebuild complet → `transform` rejouable sans doublon.
- **Commande quotidienne** : `eds run-daily` enchaîne `ingest(jour)` + `transform` + `verify` dans **un seul** `meta.runs`, avec code retour propre.
- **Planification** : `crontab scripts/crontab.example` — tous les jours à 02h15 ; sur échec, une ligne [ALERTE] est écrite dans `logs/cron.log` et le run est marqué `error`.
- **Journalisation** : `logs/pipeline-AAAAMMJJ.log` (console + fichier).
- **Reprise sur incident** : `make status` pour identifier le run en échec, corriger la cause, puis `make replay DATE=<jour>` (ré-ingère + rejoue les transformations).
- **Contrôle de fiabilité** : `make verify` — 12 contrôles, `exit` ≠ 0 si l'un casse ; branché sur `run-daily` et documenté dans `.claude/skills/eds-run/SKILL.md`.

11. Limites & recommandations

Alternatives écartées (et quand elles deviendraient pertinentes)

Piste	Écartée parce que	Basculer si...
dbt-clickhouse pour les transfos	on reste au plus près de la fiche-sujet (SQL + Python) et on limite les dépendances	le nombre de modèles SQL explose, besoin de tests et doc auto
Dagster / Airflow	lourd pour un laptop ; <code>cron</code> + <code>meta.runs</code> suffit à la démonstration	multiplication des sources, besoin de <i>backfill</i> et de dépendances complexes
Superset au lieu de Metabase	mise en place plus lourde ; le <i>row-level security</i> n'est pas nécessaire ici	besoin de filtrage fin par utilisateur au sein d'une même table

Passage à l'échelle du monitoring

Le flux monitoring est le plus volumineux et grossira. Le traiter comme un **flux autonome** (aucune jointure inter-tables à honorer au nettoyage) facilite ce passage à l'échelle. Recommandations : cluster ClickHouse (sharding par `stay_id`), politique de **rétenion** (TTL sur les partitions anciennes), **agrégats pré-calculés** (Materialized Views pour les alertes par jour) plutôt qu'un scan complet à chaque lecture.

Qualité & sécurité

- Étendre les contrôles silver (doublons de `stay_id` divergents entre dépôts, valeurs de `admission_mode` / `discharge_mode` hors nomenclature).
- `silver.monitoring` (flux autonome) conserve **520 relevés (1,3 %)** portant sur un séjour écarté par un contrôle qualité silver : **conservés** (téléométrie réelle), mais ce taux de rattachement partiel est à **remonter au CHU** comme signal de qualité à la source.
- Le référentiel `services` n'est pas encore matérialisé en silver comme pathologies. **Fait dans la Partie II** : `silver.services` (promu + enrichi) rend la chaîne symétrique.
- Chiffrement au repos des volumes, journalisation des accès Metabase, rotation du sel de pseudonymisation avec table de correspondance sécurisée.
- Sur ce jeu, `discharge_mode` est renseigné sur tous les séjours clos ; sur un dépôt réel, un taux de non-renseignement serait à suivre comme problème **à la source**.

Partie II — Évolution du sujet : actes médicaux & description des services

Reçue après la finalisation de la Partie I. Consigne : « faites évoluer votre entrepôt — sans tout refaire, sans rien casser ». La Partie I (§ 1-11) reste le socle ; cette partie est **additive**. Sources : docs/SUJET-EVOLUTION-nouvelles-kpi.pdf, docs/context/07-evolution-contexte.md à 09-corrige-niveau1-comparatif.md.

12. Contexte de l'évolution

Le CHU **ajoute** des données (il n'en modifie aucune), dans un dépôt daté **2026-08-29** :

Fichier	Format	Contenu	Volume
referentiels/2026-08-29/description_service.csv	CSV	enrichit les services : categorie, capacite_lits, pole	7 lignes (NEURO absent)
referentiels/2026-08-29/ccam.csv	CSV	nomenclature des actes : code_ccam, libelle, tarif_euros (T2A)	8 codes
actes/2026-08-29/actes.p arquet	Parquet	nouveau flux de faits : stay_id, code_ccam, acte_ts	8 112 actes

service_label → categorie → pole sont **trois niveaux d'agrégation croissants** du même axe « service » (analyser par service, par catégorie, par pôle) — une hiérarchie, pas une redondance.

Cinq KPI sont demandés (E1 activité/DMS par catégorie · E2 actes par service · E3 actes par type · E4 densité d'actes par lit · E5 montant T2A par service) avec **deux pièges explicites** : (1) le référentiel de description est **incomplet** (NEURO non décrit) ; (2) « actes par service » — le service est porté par le **séjour**, pas par l'acte.

13. Analyse — concevoir le silver à partir des KPI

Démarche : **partir des KPI**, en déduire les tables strictement nécessaires (détail : docs/context/08-evolution-silver-kpi.md).

KPI	Table créée / étendue	Justification
E1	silver.services → gold.dim_service (+ categorie, capacite_lits, pole)	référentiel promu en silver (comme pathologies) car la description doit être nettoyée / complétée avant le gold
E2, E5	silver.actes → gold.fact_acte	fait « acte » (grain = 1 acte) ; service_code résolu dans le silver
E3	silver.ccam → gold.dim_ccam	référentiel matérialisé (codes CCAM observés), miroir de pathologies
E4	capacite_lits de gold.dim_service	dénominateur de densité

Piège 1 — service non décrit (NEURO)

silver.services part de la **liste autoritaire** bronze.ref_services (**8 services**) et LEFT JOIN la description. NEURO, absent de description_service.csv, est **conservé** : categorie / pole = '(non décrit)', capacite_lits = NULL, is_described = 0, tracé clean.rejects (service_sans_description — **audit, pas exclusion**).

- L'exclure ferait perdre 1 208 séjours / 1 471 actes aux analyses « par catégorie » et casserait la réconciliation avec fact_sejour.
- Deviner sa catégorie reviendrait à **inventer** une donnée absente de la source.
- Résultat : KPI E1 montre un groupe (non décrit) explicite ; KPI E4 densité = NULL pour NEURO. Le trou est **visible et remontable au CHU**.

Piège 2 — le service vient du séjour


Le `service_code` (et le `patient_hash`) sont résolus **une seule fois**, dans `silver.actes`, par `bronze.actes` → `bronze.sejours`. `gold.fact_acte` porte ce `service_code` **dénormalisé** → **aucune vue gold ne joint** `fact_acte` à `fact_sejour`. Joindre deux tables de faits de grains différents (acte / séjour) ferait exploser les lignes (produit acte × séjour du même patient) et fausserait tous les comptages : un fait ne se joint qu'à des **dimensions**. Contrôle `11_actes_service_provenance` : 0 écart entre le service de l'acte et celui de son séjour.

Décisions de nettoyage des actes (miroir des diagnostics)

Un acte porté par un séjour écarté pour **dates incohérentes** reste **réel et facturable** : on le **conserve** (82 actes), service et patient pris dans `bronze.sejours`. On n'écarte (et trace) que l'acte au `stay_id` totalement inconnu ou au `code_ccam` hors nomenclature — **0 cas** sur ce dépôt.

14. Modèle après évolution — comparatif

Couche silver — 5 tables → 8



	Partie I	Partie II
Tables silver	patients, sejours, diagnostics, pathologies, monitoring	+ services, actes, ccam
Chaîne	patients → sejours → diagnostics → pathologies ; monitoring autonome	idem + services → sejours et sejours → actes ← ccam
diagnostics	rattaché à un séjour <i>valide</i>	rattaché à un séjour <i>réel</i> (porte patient_hash) — cf. § 16

Couche gold — schéma en étoile étendu




Schéma en étoile après évolution

	Partie I	Partie II
Faits	fact_sejour	+ fact_acte (grain = 1 acte ; mesure = tarif_euros)
Dimensions	dim_patient, dim_service, dim_cim10	dim_service enrichie (categorie, capacite_lits, pole) + dim_ccam
Règle respectée	KPI par X ⇒ X dimension, KPI issu du fait	idem — fact_acte ne se joint qu'à des dimensions, jamais à fact_sejour

Non-régression

gold.fact_sejour = **6 729** (inchangé). Les 6 KPI de la Partie I sont inchangés dans leur résultat (test test_non_regression_fact_sejour, contrôle 01). dim_service gagne des colonnes sans en retirer → les vues existantes (qui ne lisent que service_label) ne bougent pas.


15. Les 5 nouveaux indicateurs — définitions & valeurs

Vues gold.kpi_pilotage_*, SQL SECURITY DEFINER, GRANT SELECT ... TO role_pilotage (même public que le pilotage). Valeurs sur le jeu fourni (8 112 actes) :

KPI	Définition	Valeur (extrait)
E1 · Activité + DMS par catégorie	count() séjours + avg(los_hours)/24 (clos) GROUP BY categorie	medecine 2 652 séj / 5,71 j · urgences 1 423 / 2,15 j · (non décrit) 1 208 / 7,06 j (NEURO) · reanimation 467 / 9,05 j
E2 · Actes par service	count() actes par service + count() / nb_séjours_du_service	CARDIO 1 935 actes (1,21 / séjour) · URGENCES 1 731 (1,22) · NEURO 1 471 (1,22) · ONCO 241 (1,14)
E3 · Actes par type	count() + part GROUP BY code_ccam	Radiographie du thorax 1 043 (12,9 %) · Consultation de suivi 1 039 · Coronarographie 1 030 — répartition ≈ uniforme sur 8 actes
E4 · Densité d'actes par lit	count(actes) / capacite_lits par service	URGENCES 86,6 · CARDIO 64,5 · PNEUMO 36,0 · REA 35,2 · ... · NEURO = NULL (service non décrit)
E5 · Montant T2A par service	sum(tarif_euros) par service	CARDIO 521 655 € · URGENCES 478 585 € · NEURO 393 850 € · ... · ONCO 64 265 € (total ≈ 2,20 M€)

Restitution — 3e dashboard Metabase

make dashboards provisionne un **3e dashboard** « *Pilotage — plateau technique & T2A* » (5 cartes, collection Pilotage), à côté des 2 dashboards de la Partie I qui restent intacts. Cloisonnement inchangé : ro_recherche sur ces vues → ACCESS_DENIED.



Dashboard plateau technique & T2A

16. Comparatif — alignement sur la feuille de réponses officielle (corrigé niveau 1)

Détail complet : docs/context/09-corrige-niveau1-comparatif.md. La feuille de réponses officielle (jeu figé seed 42) **confirme nos points de contrôle silver** (18 000→6 000 · 6 797→6 729 · 41 778→40 920) mais **révèle des définitions de KPI différentes** des choix initiaux de la Partie I. Alignement effectué :

KPI	Avant	Après (feuille)	Cause
Réadmission 30 j	10,54 % (637 / 6 046 clos)	11,59 % (780 / 6 729)	dénominateur = tous les séjours ; réadmission vers un séjour encore ouvert comptée
Activité urgences	admission_mode = 'urgence' (tous services)	service URGENCES par jour	« urgences » = le service, pas le mode
Alertes constantes	FC < 40 / > 120 · T° < 35	SpO2 < 92 · FC < 50 / > 100 · T° > 38,5	seuils cliniques différents
Prévalence	diagnostic principal seul	tous diagnostics , y compris séjours à dates fausses → N39 = 2 234	prévalence épidémiologique = tout patient porteur
Cohorte	age_band × sex global, tranches larges	par pathologie principale × tranche décennale × sexe	granularité et bornes

Seul impact silver : silver.diagnostics porte désormais patient_hash et **conserve les 127 diagnostics** des 68 séjours écartés pour dates incohérentes (le codage est valide, seules les dates sont fausses) — ces diagnostics restent **hors** fact_sejour. Un contrôle verify dédié (09_corrige_niveau1) **verrouille** les repères chiffrés de la feuille.

17. Non-régression & fiabilité — 12 contrôles [verify](#)

#	Contrôle	Portée
01-03	fait ↔ silver ↔ bronze (séjours, patients)	Partie I
04	k-anonymat : aucune cohorte recherche < 5 exposée	Partie I
05	cohérence temporelle résiduelle	Partie I

#	Contrôle	Portée
06	Σ nb_passages urgences = countIf(service = URGENCES)	Partie I (réaligné)
07	bornes physiologiques monitoring	Partie I
08	intégrité diagnostics → pathologies → référentiel	Partie I
09	repères de la feuille de réponses atteints	corrigé niveau 1
10	count(fact_acte) = count(silver.actes)	évolution
11	service de l'acte = service de son séjour (piège 2)	évolution
12	intégrité actes → ccam → référentiel	évolution

Reprise : make replay DATE=2026-08-29 ré-ingère le dépôt évolution et rejoue les transformations. make all reste valable à froid (l'évolution est dans data/source-filestorage/, versionnée).